Lésions de la peau sous contraintes logiques

Mini-projet IA hybride, sujet 4 · Groupe 4 : Lina Khadly, Alexis Dechenais · ISIS Castres, 5e année DSIA · octobre 2026

> Avec seulement 10 % des étiquettes fines, imposer la hiérarchie bénin / malin fait passer l'AUC de détection des lésions malignes de 0,817 à 0,862 (et de 0,776 à 0,859 avec 2 %), sans améliorer la reconnaissance du type exact. Ce rapport présente comment nous l'avons mesuré et pourquoi.

1. Problème et idée hybride

Question clinique. Classer des images dermatoscopiques en sept types de lésions, avec des sorties cohérentes avec la hiérarchie médicale (bénin ou malin), une incertitude exploitable et peu d'images annotées finement.

Idée hybride. On ajoute au réseau une connaissance symbolique simple : chaque type appartient à un groupe, et une prédiction « mélanome » doit aller avec « malin ». Comme dans le TP MNIST, où la règle *somme* = $a + b$ reliait une étiquette globale aux chiffres, la règle *type* ⇒ *groupe* relie une étiquette globale (le groupe, que donne une biopsie) aux types fins, plus coûteux à annoter. Questions : la contrainte améliore-t-elle la performance quand les étiquettes fines sont rares ? Rend-elle les sorties cohérentes et l'incertitude utilisable ? Quelles erreurs restent, et à quelle brique les attribuer ?

2. Données et connaissance

DermaMNIST (MedMNIST v2, Yang et al., 2023) est une version 28×28 en couleur de **HAM10000** (Tschandl et al., 2018) : 7 007 images d'entraînement, 1 003 de validation, 2 005 de test. L'ordre des classes a été lu dans les métadonnées et vérifié par les noms.

Déséquilibre. Les nævus font 67 % des images : répondre toujours « nævus » donne déjà 67 % de précision. Nous suivons donc la précision équilibrée, le F1 macro, le rappel du mélanome et l'AUC bénin / malin.

Régime peu supervisé. Nous gardons le type de 10 % des images d'entraînement (701 images, tirage stratifié par classe, fixé pour tous les modèles) ; pour les autres, seul le groupe est connu.

Type	Groupe	Entraînement
nv : nævus	bénin	4 693 (67,0 %)
mel : mélanome	**malin**	779 (11,1 %)
bkl : kératose bénigne	bénin	769 (11,0 %)
bcc : carcinome basocellulaire	**malin**	359 (5,1 %)
akiec : kératose actinique, carcinome intraépithélial	**pré-malin**	228 (3,3 %)
vasc : lésion vasculaire	bénin	99 (1,4 %)
df : dermatofibrome	bénin	80 (1,1 %)

Hiérarchie. Le regroupement s'appuie sur HAM10000, qui décrit bcc et mel comme malins, akiec comme pouvant évoluer en carcinome épidermoïde invasif, et nv, bkl et df comme bénins ; les lésions vasculaires (angiomes, granulomes pyogéniques) n'y sont pas qualifiées explicitement, nous les rangeons avec les bénins. La kératose actinique est pré-maligne, avec un risque de progression faible, moins d'une sur 1 000 par an (de Berker et al., 2017) ; pour un dépistage, nous choisissons de la traiter comme un cancer. La hiérarchie est codée par une matrice H de taille 7×2, avec $H[k, g] = 1$ si le type k appartient au groupe g.

3. Méthode

Trois modèles partagent le même petit CNN (4 couches convolutives, environ 34 000 paramètres) et ne diffèrent que par leurs briques.

Modèle	Tête type (7)	Tête groupe (2)	Pertes logiques	Décodage cohérent	Images utilisées à 10 %
R : référence non hybride	oui	non	non	–	les 701 images étiquetées
M : multi-tâche sans règle	oui	oui	non	oui	toutes (groupe connu)
H : hybride	oui	oui	oui	oui	toutes (groupe connu)

Notons p_k la probabilité du type k, q_g celle du groupe g, et $G(g)$ les types du groupe g. Le modèle H ajoute deux pertes issues de la règle *type* ⇒ *groupe*.

(a) Groupe observé ⇒ le type est l'un de ses enfants. Si la lésion est maligne, son type est akiec, bcc ou mel. Cette perte entraîne la tête type sur les images sans étiquette fine, comme la règle d'addition du TP MNIST :

$$\mathscr{L}_a = -\log \Sigma_{k \in G(g_{obs})} p_k$$

(b) Cohérence entre les deux têtes (*semantic loss*, Xu et al., 2018). La probabilité que le couple (type, groupe) respecte la hiérarchie est la somme des $p_k \cdot q_{g(k)}$. Cette perte n'utilise aucune étiquette :

$$\mathscr{L}_b = -\log \Sigma_k p_k \cdot q_{g(k)}$$

Variante floue testée en ablation : la t-norme de Łukasiewicz (Badreddine et al., 2022), qui pénalise $\max(0, p_k - q_{g(k)})$ pour chaque implication. **(c) Décodage cohérent :** on renvoie le type qui maximise $p_k \cdot q_{g(k)}$ et son groupe, si bien que les deux sorties ne peuvent plus se contredire.

Protocole. Même nombre de pas pour tous (1 200 lots de 128, AdamW, symétries aléatoires) ; en régime 10 %, chaque lot de M et H contient moitié d'images étiquetées. Trois graines pour l'expérience principale et les ablations. Pas d'arrêt précoce : la validation sert seulement à la température et à la prédiction conforme, pour éviter toute fuite vers le test.

4. Résultats

La hiérarchie améliore la détection bénin / malin quand les étiquettes fines sont rares, mais pas la reconnaissance du type exact (moyenne ± écart-type sur 3 graines, jeu de test).

Mesure	R, 10 %	M, 10 %	H, 10 %	R, 100 %	H, 100 %
Précision équilibrée (7 types)	**0,389 ± 0,014**	0,384 ± 0,018	0,369 ± 0,010	**0,438 ± 0,007**	0,377 ± 0,003
Rappel du mélanome	0,344 ± 0,024	**0,354 ± 0,004**	0,324 ± 0,013	**0,374 ± 0,012**	0,324 ± 0,017
AUC bénin / malin	0,817 ± 0,006	0,858 ± 0,005	**0,862 ± 0,001**	**0,885 ± 0,002**	0,884 ± 0,003
Incohérence entre têtes, avant décodage	une seule tête	5,7 %	**3,8 %**	une seule tête	3,3 %
ECE, décodage brut	0,143	0,087	**0,075**	0,021	0,026

Le décodage cohérent ramène l'incohérence à 0 % pour M et H. À 100 %, la référence est meilleure : le groupe se déduit alors du type et n'apporte rien de nouveau.

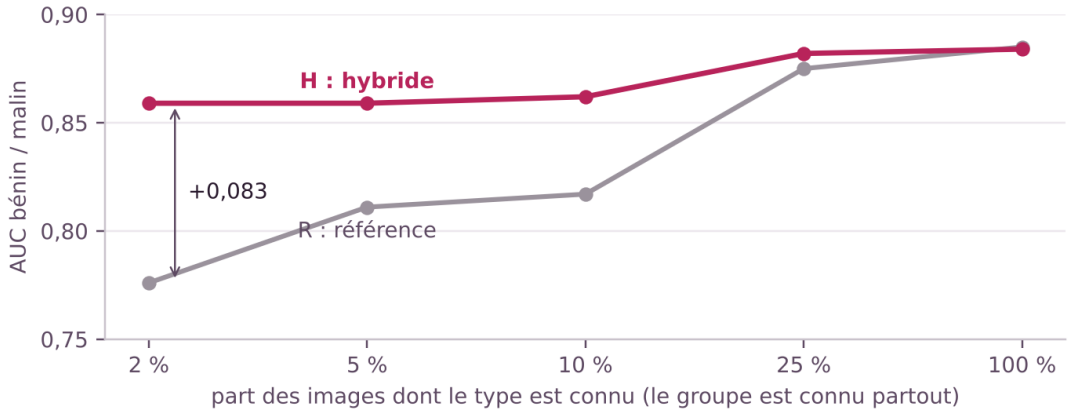


Figure 1. Avec 2 % des étiquettes fines, l'hybride garde une AUC bénin / malin de 0,86 (0,78 pour la référence). 10 % et 100 % : moyenne de 3 graines ; 2 %, 5 % et 25 % : une graine.

La détection des malins de H dépend du groupe, connu partout, et presque pas des étiquettes fines ; les courbes se rejoignent à partir de 25 %. Sur la précision équilibrée, R reste au-dessus de H à toutes les fractions, sauf à 2 % où elles sont égales (0,337 contre 0,336).

Ablations (régime 10 %, 3 graines). Sans la règle (a), l'AUC malin passe de 0,862 à 0,856 et le rappel du mélanome de 0,324 à 0,306 : c'est la brique qui transmet le groupe à la tête type. Sans la cohérence (b), la précision équilibrée monte à 0,385 et le rappel malin à 0,509 : cette perte n'aide pas ici. Łukasiewicz fait un peu mieux que

la *semantic loss* (0,384 et 0,500), sans doute parce que sa pénalité est bornée alors que le −log devient très grand pour une prédiction incohérente. Ces écarts de 1 à 2 points sont du même ordre que les écarts-types. Enfin, M fait presque aussi bien que H : l'essentiel du gain vient de l'**étiquette de groupe**, plus que de la logique.

5. Cas difficiles et incertitude

Classes rares. Le dermatofibrome n'est presque jamais reconnu (rappel 0 à 0,09 ; 8 images étiquetées à 10 %). À 10 %, H perd sur les bénins rares (vasc 0,138 contre 0,264 pour R ; df 0,014 contre 0,087) et gagne sur nv : pour satisfaire « bénin ⇒ bkl, df, nv ou vasc », le plus simple est de tout mettre sur nv. **Cas où la règle s'applique.** Quand les deux têtes de M se contredisent (4,8 % des images à 10 %), chacune a raison sur le groupe une fois sur deux environ ; sur ces images, H trouve le bon groupe dans 64 % des cas, contre 53 % pour M.

Perturbations et hors distribution. Sous sous-exposition, l'AUC malin de H reste à 0,642 contre 0,417 pour R (10 %) ; le type exact s'effondre pour tous (précision équilibrée ≈ 0,15). Face à des chiffres manuscrits MNIST, tous les modèles répondent avec une confiance de 0,99 à 1,00 et les classent presque tous malins : la hiérarchie choisit parmi les 7 types connus, elle ne sait pas dire « aucun ».

Calibration et escalade. À 10 %, les modèles sont trop sûrs d'eux (température apprise $T = 1{,}8$) ; la mise à l'échelle par température (Guo et al., 2017) ramène l'ECE de 0,14 à 0,03 pour R et de 0,11 à 0,03 pour H. Avec des ensembles conformes à 90 % (Angelopoulos et Bates, 2021), la couverture mesurée est de 0,89 à 0,91 pour tous. Règle d'escalade : transmettre au dermatologue quand l'ensemble contient un type malin et un type bénin. À 10 %, H escalade 22,5 % des images contre 42,8 % pour R, mais laisse passer 28,1 % des malins sans alerte contre 19,6 % : moins de fatigue d'alerte, plus de cancers manqués ; ni l'un ni l'autre n'est acceptable pour un dépistage réel.

6. Analyse d'erreurs par brique

Le goulot d'étranglement est la perception, pas la logique : 97 % des erreurs de H viennent du réseau (H à 10 %, graine 0 : 534 erreurs sur 2 005 images). La confusion la plus fréquente et la plus dangereuse est **mélanome → nævus** (117 des 223 mélanomes de test). La hiérarchie ne peut pas corriger les erreurs intra-groupe. Le décodage cohérent introduit 15 erreurs et en corrige 5, mais chacune de ses décisions est traçable jusqu'à la règle appliquée.

Brique responsable	Erreurs	Part
Perception du groupe (mauvaise famille)	291	54 %
Perception intra-groupe (bon groupe, mauvais type)	228	43 %
Décodage symbolique (la tête type avait raison)	15	3 %

7. Discussion et conclusion

Une règle aide dans la mesure de l'information qu'elle apporte : la hiérarchie bénin / malin informe sur le groupe, et c'est sur le groupe qu'elle aide.

Dimension	Verdict (régime 10 %)
Performance, types fins	R un peu meilleur (0,389 contre 0,369)
Performance, bénin / malin	**H nettement meilleur** (AUC 0,862 contre 0,817 ; 0,859 contre 0,776 à 2 %)
Cohérence	H : 3,8 % de conflits entre têtes, 0 % après décodage
Calibration	équivalents après température (ECE ≈ 0,03)
Robustesse	H plus robuste pour bénin / malin ; tous aveugles hors distribution
Explicabilité	H : type, groupe, règle appliquée, ensemble conforme, décision
Coût	identique (130 paramètres de plus, ≈ 37 s d'entraînement sur CPU)

Pourquoi la contrainte n'aide pas le type exact. Comme la règle du maximum dans le TP MNIST, « type ⇒ groupe » est peu informative : elle ne dit rien à l'intérieur d'un groupe et n'a pas d'« ancre » comparable à 0 + 0 = 0 pour l'addition. Elle renforce même le biais vers la classe dominante de chaque groupe. Pour aider les types, il faudrait une connaissance plus fine, par exemple des critères dermoscopiques (règle ABCD) reliés aux types.

Limites. Images 28×28 (l'objectif était l'apport de la contrainte, pas l'état de l'art) ; 3 graines seulement, une pour les fractions intermédiaires, les perturbations, le hors distribution et l'analyse d'erreurs ; aucune pondération des

classes ; une seule population (HAM10000 : patients principalement d'Autriche et d'Australie, peaux claires). **Pistes.** Pondérer les classes ; ajouter un contrôle qualité et un détecteur hors distribution en entrée ; reformuler le modèle en DeepProbLog (Manhaeve et al., 2018) ; choisir une règle d'escalade plus prudente, car manquer un mélanome coûte bien plus qu'une consultation de trop.

Références

- Tschandl P., Rosendahl C., Kittler H. *The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions.* Scientific Data 5, 180161 (2018). doi:10.1038/sdata.2018.161
- Yang J. et al. *MedMNIST v2 – A large-scale lightweight benchmark for 2D and 3D biomedical image classification.* Scientific Data 10, 41 (2023). doi:10.1038/s41597-022-01721-8 ; données : zenodo.org/records/10519652
- de Berker D. et al. *British Association of Dermatologists' guidelines for the care of patients with actinic keratosis 2017.* British Journal of Dermatology 176(1), 20–43 (2017). doi:10.1111/bjd.15107
- Xu J., Zhang Z., Friedman T., Liang Y., Van den Broeck G. *A Semantic Loss Function for Deep Learning with Symbolic Knowledge.* ICML 2018.
- Badreddine S., d'Avila Garcez A., Serafini L., Spranger M. *Logic Tensor Networks.* Artificial Intelligence 303 (2022).
- Manhaeve R. et al. *DeepProbLog: Neural Probabilistic Logic Programming.* NeurIPS 2018.
- Guo C., Pleiss G., Sun Y., Weinberger K. *On Calibration of Modern Neural Networks.* ICML 2017.
- Angelopoulos A., Bates S. *A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification.* arXiv: 2107.07511 (2021).

Code, données et réexécution : voir le README du dépôt.